

学士論文

VLM を用いた長期ロボットタスクにおける工程文脈依存的不
確実性診断

Process-Context-Dependent Uncertainty Diagnosis for Long-Horizon
Robot Tasks Using Vision-Language Models

大規模ネットワークサイエンス研究室

瓜生 滉宜

指導教員 大知 正直 准教授

2027 年 2 月

大分大学 理工学部 理工学科 知能情報システムプログラム

要 旨

近年、Vision-Language-Action Model (VLA) や Vision-Language Model (VLM) を用いたロボット操作は、物体を掴む、置く、移動するなどの短期的な作業で大きく進展している。一方で、机上片付けや家庭内支援のような長期ロボットタスクでは、現状の手法は次の動作を生成することには有効であっても、現在の作業段階で何が不確かであり、その不確かさにどう対処すべきかを適切に判断することが難しい。本研究の目的は、長期ロボットタスクにおいて、ロボットが現在どの作業段階にあり、それまでにどのような操作を行ってきたかに基づいて、不確かな状態への対処を適切に切り替えるための診断方法を明らかにすることである。この目的を達成するうえでは、同じ見え方であっても、現在の作業段階やこれまでの作業履歴に応じて、実行、再観測、人間への確認、安全停止、後回しのいずれを選ぶべきかを判断する基準をどのように表現するかが課題となる。本研究では、ロボットが現在見ている画像、これまでの作業履歴、現在の作業段階、次に取り得る作業候補、各段階で満たすべき条件を入力として、不確かな状態を診断し、その結果に応じて適切な対処行動へ分岐する手法を提案する。そのために、VLM を次の動作を直接生成するためではなく、判断に必要な情報が十分か、不確かさの原因は何か、その不確かさが作業にどの程度関わるか、どのように対処すべきか、実行時にどのような安全条件が必要かを整理して出力するために用いる。評価では、同じ視覚情報に対して作業段階だけを変えた対照ペアを設計し、VLM が状況に応じて分岐判断を切り替えられるかを検証する。また、追加学習を行わない VLM や入力条件を簡略化した場合との比較により、この診断方法の有効性を評価する。さらに、実機デモを通じて、診断結果が安全な分岐制御に接続可能かを確認する。本研究により、ロボットが「分からない」状態を一律に扱うのではなく、現在の作業段階やこれまでの作業履歴に応じて、実行する、見直す、聞く、止まる、後回しにする判断を切り替えるための基礎的知見を得ることを目指す。

キーワード VLM, 長期ロボットタスク, 不確実性診断, 工程文脈, Physical AI

目次

1	序論	1
1.1	本章の概要	1
1.2	研究背景	1
1.3	問題提起	1
1.4	研究目的と対象範囲	2
1.5	研究課題	2
1.6	方法論	3
1.7	本研究の貢献	3
1.8	本論文の構成	3
2	関連研究	5
2.1	本章の概要	5
2.2	VLA と Physical AI	5
2.3	長期タスク・履歴・記憶を扱う研究	5
2.4	VLM によるロボット操作支援	6
2.5	Active Perception と追加観測	6
2.6	Ask-user と Human-Robot Interaction	6
2.7	失敗検出・実行監視・過程理解	7
2.8	不確実性下の計画と World Model	7
2.9	本研究の位置づけ	7
3	提案手法	8
3.1	本章の概要	8
3.2	手法の全体像	8
3.3	問題定式化	8
3.4	入力と出力	9
3.5	不確実性原因の定義	9
3.6	処理分岐の定義	10
3.7	構造化診断アルゴリズム	10
3.8	実装上の工夫	11
4	データと実験設計	12
4.1	本章の概要	12
4.2	データセット	12
4.3	実施すべき実験項目	13
4.4	実施順	15
4.5	評価指標	16
4.6	ベースライン手法	17

4.7	実験設定	18
4.8	対照ペア例	18
5	実験 1	19
5.1	本章の概要	19
5.2	実験 1 の設定	19
5.3	評価の観点	19
5.4	ベースラインとの比較	20
5.5	考察	20
6	実験 2	21
6.1	本章の概要	21
6.2	実験 2 の設定	21
6.3	評価の観点	21
6.4	実験 3：実機分岐デモ	22
6.5	考察	22
7	考察	23
7.1	本章の概要	23
7.2	結果の解釈	23
7.3	手法の限界	23
7.4	今後の方向性	24
8	結論	25
8.1	本研究のまとめ	25
8.2	今後の課題	25
A	付録	26
A.1	補足資料	26
	参考文献	27

目 次

表 目 次

3.1	Resolution mode の定義	10
4.1	データ数の目安	13
4.2	比較手法	17
4.3	評価指標に対する統計検定	18
4.4	同一視覚状態・異なる工程文脈の対照ペア例	18
6.1	実機デモにおける分岐別成功基準	22

第 1 章 序論

1.1 本章の概要

本章では、研究の背景、問題提起、研究目的、研究課題、方法論の要点、本研究の貢献、および本論文の構成を述べる。

1.2 研究背景

Physical AI の発展により、AI は画像や文章を理解するだけでなく、物理世界で行動するロボットへ接続されつつある。特に、VLA は視覚、言語、行動を統合し、汎用的な操作能力をロボットへ与える方向として注目されている。RT-2 や OpenVLA に代表される研究は、短期的な操作を幅広い指示から実行する可能性を示している [1-3]。

しかし、実環境で必要となる作業は、単発の把持や移動だけではない。机上片付け、収納、配膳、掃除補助のような長期ロボットタスクでは、複数の工程を順に進める必要がある。その過程では、対象物の有無、遮蔽、所有者、危険性、ユーザ意図、作業履歴との不一致など、多様な不確実性が発生する。したがって、ロボットには「次に何をするか」だけでなく、「いま何が分かっているのか」「その不確実性をどう扱うべきか」を判断する能力が求められる。

1.3 問題提起

既存研究では、不確実な場合に人間へ質問する研究、追加観測により見えない対象を確認する研究、失敗を検出する研究、安全上危険な動作を抑制する研究が個別に進められている [4-6]。しかし、長期タスク中で

は、同じ不確実性でも工程文脈によって適切な処理が変わる。

例えば、机上片付けにおいて「コップの中身が見えない」という不確実性は、コップを動かす直前であれば安全上の理由から stop または ask_user が必要である。一方で、現在の工程がペンの片付けであり、コップ操作が後工程であれば defer が妥当である。また、「対象物が見えない」という状況も、探索中なら reobserve、まだ未実行なら act、配置済み履歴があるなら reobserve へ変化しうる。したがって、長期ロボットタスクでは、不確実性の有無だけでなく、その不確実性が現在工程においてどの処理分岐へ接続されるべきかを診断する必要がある。

1.4 研究目的と対象範囲

本研究の目的は、長期ロボットタスクにおいて、VLMを用いて工程文脈依存的な不確実性を診断し、現在の不確実性を act / reobserve / ask_user / stop / defer のいずれへ接続すべきかを判定する方法を検討することである。

対象タスクは、机上片付けを想定した長期ロボットタスクとする。対象物はコップ、ペン、小物、布、箱、ケーブル、スポンジブロックなどを含み、各工程には「見つかっているか」「安全に持てるか」「確認が済んでいるか」などの工程条件が存在する。本研究では、大規模な world model や task and motion planning そのものを新規提案することは目的とせず、あくまで次工程へ進む前の工程条件不確実性を診断する前段モジュールに焦点を当てる。

1.5 研究課題

本研究では、以下の三点を主要課題として設定する。

1. 長期ロボットタスク中の不確実性を、工程文脈と処理分岐の観点から整理する。

2. VLM による不確実性診断手法を構成し、証拠充足性、不確実性原因、工程関連性、処理分岐を構造化して出力させる。
3. 提案手法が実際の長期タスクにおいて有効かを、同一視覚状態・異なる工程文脈の対照評価と実機デモにより検証する。

1.6 方法論

本研究では、現在画像、作業履歴、現在工程、次工程候補、工程条件リストをVLMへ入力する。VLMは各工程条件について、証拠が十分か、不確実性の原因は何か、現在工程において重要か、どの処理分岐が適切かを構造化形式で出力する。提案手法の特徴は、単に「次にどうするか」を直接出力させるのではなく、中間的な診断を経由して最終分岐を決定する点にある。

1.7 本研究の貢献

本研究の貢献は以下の三点である。

1. 長期ロボットタスク中の不確実性を、工程文脈に応じた処理分岐として整理する。
2. VLMを用いて、証拠充足性、不確実性原因、工程関連性、処理分岐を構造化して診断する手法を提案する。
3. 同一視覚状態・異なる工程文脈の対照評価により、VLMが文脈依存的に act / reobserve / ask_user / stop / defer を切り替えられるかを検証する。

1.8 本論文の構成

本論文の構成は以下のとおりである。第2章では関連研究を述べる。第3章では提案手法を述べる。第4章ではデータと実験設計を述べる。第

5章では実験1を中心とした分類性能評価を述べる。第6章では実験2および実験3を通じた文脈依存性評価と実機デモを述べる。第7章では考察を述べる。第8章では結論と今後の課題を述べる。

第 2 章 関連研究

2.1 本章の概要

本章では、本研究に関連する先行研究を、VLA と Physical AI、長期タスクと履歴利用、VLM による操作支援、Active Perception、Human-Robot Interaction、失敗検出、不確実性下の計画の観点から整理し、本研究の位置づけを明確にする。

2.2 VLA と Physical AI

RT-2 は web 規模知識をロボット制御へ転移する VLA の方向性を示し、OpenVLA はオープンソースでの実装可能性を広げた [1,2]。また、RT-1 は大規模実機データに基づく行動生成の基礎を築いている [3]。これらの研究は、視覚・言語・行動を統合し、ロボットに汎用的な操作能力を与える枠組みとして重要である。一方で、本研究は VLA そのものを訓練するのではなく、VLA や primitive 実行の前段で、現在工程の不確実性を診断する補助モジュールを対象とする。

2.3 長期タスク・履歴・記憶を扱う研究

TraceVLA、MemoryVLA、MAP-VLA は、長期ロボット操作において履歴、軌跡、記憶を利用する研究である [7-9]。これらは長期タスクにおける状態維持や文脈保持の重要性を示している。本研究も履歴と現在工程を扱う点では共通するが、目的は行動生成性能の向上ではなく、同じ不確実性が工程文脈によって異なる処理分岐へ割り当てられるかを診断することにある。

2.4 VLM によるロボット操作支援

MOKA は、VLM に画像上のマークを与えることで、自然言語指示から操作に必要なキーポイントや affordance を推定する [10]。この方向は、VLM を直接操作支援へ利用する有効性を示している。しかし、本研究では VLM に直接操作点や次行動を出させるのではなく、工程条件が判定可能か、不確実性が何に由来するか、その不確実性をどの処理分岐へ送るべきかを診断する点が異なる。

2.5 Active Perception と追加観測

AP-VLM などの研究は、能動的に観測や探索を行うことで、操作に必要な情報を取得する枠組みを提案している [5]。これらは、視覚証拠不足に対して reobserve を選ぶ発想に近い。一方で、本研究は追加観測だけでなく、ask_user、stop、act、defer を含めて分類対象とするため、不確実性解消手段をより広い分岐集合として扱う。

2.6 Ask-user と Human-Robot Interaction

KnowNo は、LLM プランナが不確実な場合に人間へ助けを求める枠組みを示している [4]。また、GestLLM や GestOS などの HRI 研究は、人間由来情報をロボット制御へ接続する方向を発展させている [11, 12]。本研究は ask_user のみを目的とせず、不確実性が人間確認に属するのか、安全停止に属するのか、あるいは後回し可能なのかを工程文脈に基づいて判定する点に特徴がある。

2.7 失敗検出・実行監視・過程理解

AHA は、VLM を用いてロボット操作の失敗を検出し、その理由を説明する研究である [6]。RoboProcessBench は、VLM がロボット操作過程を理解できるかを評価するベンチマークを提供している [13]。これらが主として失敗後や過程理解を扱うのに対し、本研究は次工程へ進む前の工程条件不確実性を対象とする。

2.8 不確実性下の計画と World Model

TAMPURA は、不完全観測や行動結果の不確実性を含む長期計画を扱い、情報収集や不可逆リスクの回避を計画へ組み込んでいる [14]。また、V-JEPA 2 や FLARE は、将来予測や world model を通じて embodied AI の頑健性向上を目指している [15, 16]。本研究はこれらの大規模計画機構を直接提案するものではなく、現在の工程条件に関する不確実性の種類と処理分岐を VLM で診断する局所的かつ実務的な層を扱う。

2.9 本研究の位置づけ

本研究は、VLA、長期履歴利用、Active Perception、ask-user、failure detection、TAMP、world model の中間に位置する。既存研究が個別に扱ってきた「見る」「聞く」「止まる」「実行する」という機能を、長期タスク中の工程文脈依存的な不確実性診断として統合的に整理し、同一視覚状態・異なる工程文脈における処理分岐の切り替えを評価対象とする点に独自性がある。

第 3 章 提案手法

3.1 本章の概要

本章では、本研究で提案する工程文脈依存的不確実性診断手法について述べる。まず問題設定を定義し、入力と出力、扱う不確実性原因、処理分岐の定義を示したうえで、VLMによる構造化診断の流れを説明する。

3.2 手法の全体像

提案手法では、現在画像のみから次行動を直接生成するのではなく、作業履歴、現在工程、次工程候補、工程条件リストを併せてVLMに入力する。VLMは各工程条件について、証拠充足性、不確実性原因、現在工程との関連性、実行保留条件を診断し、最終的に `act / reobserve / ask_user / stop / defer` の処理分岐を出力する。

3.3 問題定式化

長期ロボットタスクを、複数の工程からなる作業とする。各工程には、次工程へ進むために確認すべき工程条件が存在する。各データ点を

$$x_i = (I_i, H_i, S_i, N_i, C_i) \quad (3.1)$$

と表す。ここで、 I_i は現在画像、 H_i は作業履歴、 S_i は現在工程、 N_i は次工程候補、 C_i は工程条件リストである。モデルは、各入力 x_i に対して、処理

分岐

$$r_i \in \{\text{act}, \text{reobserve}, \text{ask_user}, \text{stop}, \text{defer}\} \quad (3.2)$$

を予測する。

3.4 入力と出力

入力は以下の五要素から構成される。

1. 現在画像
2. 作業履歴
3. 現在工程
4. 次工程候補
5. 工程条件リスト

VLM の出力は、各工程条件に対して以下の構造を持つ。

1. evidence sufficiency : 現在の証拠で判断可能か
2. uncertainty source : 不確実性の原因
3. task relevance : 現在工程において重要か
4. resolution mode : act / reobserve / ask_user / stop / defer
5. execution guard : 実行してよいか、確認まで停止するか

3.5 不確実性原因の定義

本研究では、不確実性原因を以下のように整理する。

- visual occlusion : 遮蔽により対象が見えない
- perspective limitation : 視点不足により判断困難である
- missing execution : まだ工程が実行されていない
- history mismatch : 履歴と現在観測が整合しない
- user/context dependency : ユーザ意図や家庭ルールが必要である

表 3.1 Resolution mode の定義

mode	定義
act	現在工程に必要な条件が満たされており、追加確認なしに予定 primitive へ進める分岐
reobserve	視覚証拠が不足しており、視点変更や再撮影で判断可能になる分岐
ask_user	画像や履歴だけでは判断できず、人間由来情報が必要な分岐
stop	危険性や不可逆リスクがあり、確認なしに実行すべきでない分岐
defer	不確実性はあるが現在工程には影響せず、後工程まで延期する分岐

- non-visual safety risk : 熱さ、重さ、壊れやすさなど画像だけでは判断困難である
- irrelevant now : 現在工程ではまだ重要でない

3.6 処理分岐の定義

本研究では、resolution mode を表 3.1 の五種類に定義する。

なお、解消方法と実行安全性を分離するため、必要に応じて execution guard を併用する。例えば、人間確認が必要で、確認まで実行してはならない場合は、resolution mode を ask_user、execution guard を stop_until_confirmed として表す。

3.7 構造化診断アルゴリズム

提案手法では、VLM に直接処理分岐を選ばせるのではなく、以下の順に構造化診断を行う。

1. 現在工程に必要な工程条件を確認する。
2. 現在画像と履歴から、条件の証拠が十分かを判定する。
3. 不確実性がある場合、その原因を分類する。
4. その不確実性が現在工程を妨げるかを判定する。
5. 最終的な resolution mode と execution guard を選択する。

出力例を以下に示す。

```
{
  "condition_id": "cup_content_safety",
  "current_step": "move_cup_to_clear_workspace",
  "history": "cup_has_not_been_checked",
  "evidence_sufficiency": "insufficient",
  "uncertainty_source": "non_visual_safety_risk",
  "task_relevance": "blocking",
  "resolution_mode": "ask_user",
  "execution_guard": "stop_until_confirmed"
}
```

3.8 実装上の工夫

実装上は、VLMに自由記述で結論のみを答えさせるのではなく、工程条件ごとの診断項目を明示した構造化プロンプトを与えることで、判断根拠と分岐選択の対応を保ちやすくする。また、現在工程だけでなく次工程候補も入力に含めることで、「いま重要か」「後回し可能か」の判定精度向上を狙う。

第4章 データと実験設計

4.1 本章の概要

本章では、評価用データ、実施すべき実験項目、対照ペアの設計、比較手法、評価指標、実機デモ、および統計検定の方針について述べる。本研究の目的は、長期ロボットタスクにおいて、現在の作業段階やこれまでの作業履歴に応じて、不確かな状態への対処を適切に切り替えるための診断方法を明らかにすることである。そのため、本章では、同じ視覚情報に対して工程文脈だけを変えた場合に、VLMが実行、再観測、人間への確認、安全停止、後回しの分岐を切り替えられるかを評価する設計を示す。

4.2 データセット

机上片付けを想定した画像データを作成する。対象物は、コップ、ペン、小物、布、箱、ケーブル、スポンジブロックなどとする。各画像には、現在の作業段階、これまでの作業履歴、次に取り得る作業候補、工程条件リスト、正解となる分岐ラベルを対応付ける。これにより、同一視覚状態に対して異なる分岐が正解となる対照ペアを構成する。特に、本研究では、同じ画像に対して作業段階だけを変えた対照ペアと、作業履歴だけを変えた対照ペアの両方を準備する。

データ設計の要点は、単純な画像分類ではなく、同じ画像に対して工程文脈のみを変えた場合に、VLMが適切に分岐を切り替えられるかを評価できるようにする点にある。

表 4.1 データ数の目安

要素	数	備考
基本画像状態	40-60	机上場面の多様化を含む
工程文脈バリエーション	3-5	各画像あたり
合計評価ペア	150-250	対照ペア中心
実機デモ	10-20	シナリオ数

4.3 実施すべき実験項目

要旨で述べた研究目的を検証するため、本研究では五つの実験項目を設定する。これらの実験は、VLMが単に画像中の対象物を認識できるかを調べるものではない。同じ視覚情報であっても、現在の作業段階やこれまでの作業履歴に応じて、実行、再観測、人間への確認、安全停止、後回しのいずれを選ぶべきかを切り替えられるかを評価する。

4.3.1 実験 1：同一視覚情報・異なる作業段階の対照ペア

本実験の目的は、同じ画像でも、現在の作業段階が変わることで、適切な分岐判断を切り替えられるかを確認することである。比較条件は、同一画像に対して現在の作業段階だけを変えた条件である。例えば、対象物が見えないという同じ視覚状態であっても、探索中であれば再観測が適切であり、すでに十分な確認が済んでいる工程であれば実行または後回しが適切となる場合がある。評価指標には、分岐判断の正解率、文脈切り替え正解率、誤って実行を選んだ割合を用いる。必要なデータは、同一画像に対して作業段階だけを変えた対照ペアである。

4.3.2 実験 2：作業履歴の違いによる判断変化

本実験の目的は、現在画像が同じでも、これまでの作業履歴が異なることで判断が変わるかを確認することである。比較条件は、履歴なし、正しい履歴、矛盾する履歴である。例えば、コップの中身が分からないという同じ視覚状態でも、直前にコップを動かす工程であれば人間への確認や停止が必要になる。一方で、現在の工程が別の小物を片付ける段階であれば、後回しが適切となる可能性がある。評価指標には、文脈切り替え正解率、履歴に整合した判断率、履歴の矛盾を検出できた割合を用いる。必要なデータは、同一画像に対して異なる作業履歴を付与したデータである。

4.3.3 実験 3：追加学習を行わない VLM との比較

本実験の目的は、提案する構造化診断が、通常の VLM 判断より有効であるかを確認することである。比較条件は、追加学習なし VLM、分岐定義のみを与える条件、工程条件リストのみを与える条件、提案法である。追加学習なし VLM では、画像と指示のみから分岐を判断させる。分岐定義のみを与える条件では、act、reobserve、ask_user、stop、defer の意味だけを提示する。工程条件リストのみを与える条件では、各工程で満たすべき条件を提示する。提案法では、現在画像、作業履歴、現在の作業段階、次工程候補、工程条件リストを入力し、不確かな状態への対処を構造化して診断する。評価指標には、分岐判断の正解率、分岐判断の平均 F1 値、停止すべき場面で停止しなかった割合を用いる。必要なデータは、画像、工程文脈、工程条件、正解分岐ラベルである。

4.3.4 実験 4：入力条件を簡略化した場合との比較

本実験の目的は、どの入力情報が判断に効いているかを確認することである。比較条件は、履歴なし、現在の作業段階なし、次工程候補なし、工程条件リストなし、全入力ありである。これにより、作業履歴、現在の

作業段階、次工程候補、工程条件リストのどれが分岐判断に寄与しているかを分析する。評価指標には、分岐判断の平均F1値、文脈切り替え正解率、不要な人間確認を選んだ割合、不要な再観測を選んだ割合を用いる。必要なデータは、入力要素を段階的に除いた比較用データである。

4.3.5 実験5：実機デモによる安全な分岐制御への接続

本実験の目的は、診断結果をSO-ARM101の安全な分岐制御へ接続できるかを確認することである。比較条件は、実機を動かさない記録のみの条件、実機実行、VLM直接判断、提案法による安全確認ルール付き実行である。実機では、VLMの出力を直接モータ制御へ接続するのではなく、診断結果を事前に定義した固定動作と安全確認ルールへ変換する。不確実性が高い場合や安全条件が満たされない場合は、実行ではなく再観測、人間への確認、安全停止、後回しへ分岐させる。評価指標には、診断結果を固定動作へ変換できた割合、実機で意図した動作を完了できた割合、安全停止を選べた割合、実験ログを保存できた割合を用いる。必要なデータは、SO-ARM101、RGBカメラ、事前に定義した固定動作、実機実行ログである。

4.4 実施順

実験は、安全性と再現性を考慮し、保存画像を用いた評価から実機デモへ段階的に進める。まず、机上片付けを想定した基本画像状態を作成する。次に、各画像に、現在の作業段階、作業履歴、次工程候補、工程条件リストを付与する。その後、同一画像に対して作業段階だけを変えた対照ペアと、作業履歴だけを変えた対照ペアを作成する。各条件には、正解となる分岐ラベルを付与する。保存画像を用いた評価では、追加学習なしVLM、分岐定義のみを与える条件、工程条件リストのみを与える条件、提案法を比較する。さらに、入力条件を簡略化した比較を行い、どの情報が分岐判断に効いているかを分析する。最後に、保存画像評価で有

効性が確認できた設定を用いて、SO-ARM101 による実機デモへ接続する。

実施順は以下の通りである。

1. 机上片付けを想定した基本画像状態を作成する。
2. 各画像に、現在の作業段階、作業履歴、次工程候補、工程条件リストを付与する。
3. 同一画像に対して作業段階だけを変えた対照ペアを作成する。
4. 同一画像に対して作業履歴だけを変えた対照ペアを作成する。
5. 各条件に対して正解となる分岐ラベルを付与する。
6. 追加学習なし VLM と提案法を比較する。
7. 入力条件を簡略化した比較を行う。
8. 有効な設定を用いて、SO-ARM101 による実機デモへ接続する。

4.5 評価指標

本研究では、処理分岐分類性能だけでなく、誤実行、文脈切り替えの失敗、履歴利用、安全な実機接続も評価する。主要指標は以下のとおりである。

- 分岐判断の正解率 (Resolution Mode Accuracy)
- 分岐判断の平均 F1 値 (Macro F1)
- 誤って実行を選んだ割合 (False Act Rate)
- 文脈切り替え正解率 (Branch Contrast Accuracy: BCA)
- 不確かさの原因分類の F1 値 (uncertainty source F1)
- 停止すべき場面で停止しなかった割合 (unsafe non-stop rate)
- 不要な人間確認を選んだ割合 (unnecessary ask rate)
- 不要な再観測を選んだ割合 (unnecessary reobserve rate)
- 履歴に整合した判断率 (history-consistent accuracy)
- 履歴の矛盾を検出できた割合 (history mismatch detection rate)
- 診断結果を固定動作へ変換できた割合 (primitive conversion rate)

表 4.2 比較手法

手法	説明
追加学習なし VLM	画像と指示のみから分岐を判断する
VLM + 分岐定義のみ	act / reobserve / ask_user / stop / defer の説明のみを与える
VLM + 工程条件リスト 提案法	各工程で満たすべき条件リストを与える 現在画像、作業履歴、現在の作業段階、次工程候補、工程条件リストを用いて、不確実性への対処を構造化して診断する
入力要素を除いた比較	履歴なし、現在の作業段階なし、次工程候補なし、工程条件リストなしを比較する
人間上限	人間が同じ入力から分岐を判断する

- 実機で意図した動作を完了できた割合 (execution success rate)
- 安全停止を選べた割合 (safety stop rate)
- 実験ログを保存できた割合 (log completion rate)

特に、文脈切り替え正解率(Branch Contrast Accuracy: BCA)は、同一画像に対して工程文脈だけを変えた対照ペアにおいて、モデルが両方の分岐を正しく分類し、かつ文脈に応じて分岐を切り替えられた割合を表すため、本研究の中心的指標とする。履歴に整合した判断率と履歴の矛盾を検出できた割合は、作業履歴の違いが判断へ適切に反映されているかを確認するために用いる。診断結果を固定動作へ変換できた割合、実機で意図した動作を完了できた割合、安全停止を選べた割合、実験ログを保存できた割合は、診断結果を安全な分岐制御へ接続できるかを評価するために用いる。

4.6 ベースライン手法

比較対象は、追加学習を行わないVLM、分岐定義のみを与える条件、工程条件リストのみを与える条件、提案法、入力要素を除いた比較、人間上限である。表 4.2 に比較手法を示す。

表 4.3 評価指標に対する統計検定

比較	指標	検定
追加学習なし VLM vs 提案法	分岐判断の正解率	McNemar 検定
工程条件あり / なし	文脈切り替え正解率	McNemar 検定
追加学習なし VLM vs 提案法	誤って実行を選んだ割合	Fisher の正確確率検定
提案法 vs 入力要素を除いた比較	推論時間	Wilcoxon 符号順位検定

表 4.4 同一視覚状態・異なる工程文脈の対照ペア例

視覚状態	工程文脈	正解分岐
対象物が見えない	まだ探索中	reobserve
対象物が見えない	まだ配置していない	act
対象物が見えない	配置済み履歴あり	reobserve
コップの中身不明	コップ移動直前	ask_user
コップの中身不明	現在はペン片付け中	defer

4.7 実験設定

実験では、小型ロボットアーム、RGBカメラ、卓上作業環境、ローカル VLM、評価用アノテーションデータを用いる。実機デモでは SO-ARM101 を用い、VLM の診断結果を事前に定義した固定動作と安全確認ルールへ変換する。統計検定の方針を表 4.3 に示す。

4.8 対照ペア例

表 4.4 に、同一視覚状態・異なる工程文脈の対照ペア例を示す。これらの対照ペアでは、画像そのものは同じであっても、現在の作業段階や作業履歴によって正解分岐が変化する。

第5章 実験1

5.1 本章の概要

本章では、処理分岐分類性能を評価する実験1について述べる。評価目的、比較対象、評価方針、および実験完了後に確認したい観点を整理する。

5.2 実験1の設定

実験1の目的は、提案手法が `act` / `reobserve` / `ask_user` / `stop` / `defer` を適切に分類できるかを評価することである。比較対象は、Zero-shot VLM、VLM + 分岐定義のみ、VLM + 工程条件リストである。評価では、Resolution Mode Accuracy および Macro F1 を主要指標とし、提案手法がベースラインより安定した分類傾向を示すかを確認する。

5.3 評価の観点

本研究は執筆時点で評価進行中であるため、本節では実測結果ではなく、実験完了後に確認すべき観点を述べる。具体的には、提案手法が Zero-shot VLM や分岐定義のみを与えた条件と比べて、処理分岐分類の安定性をどの程度改善するかに着目する。特に、`ask_user` と `reobserve` の混同、`act` と `reobserve` の混同がどの程度抑えられるかを確認する予定である。

5.4 ベースラインとの比較

構造化診断を行わない Zero-shot VLM では、画像に現れた曖昧さに引きずられて、現在工程に依存した切り替えが弱くなる可能性がある。また、分岐定義のみを与えた条件では、各分岐の意味は理解できても、どの工程条件が blocking であるかの判断が不安定になると考えられる。これに対し、提案手法は工程条件、証拠充足性、不確実性原因を明示的に扱うため、実験完了後には判断の一貫性がどの程度向上するかを比較できる。

5.5 考察

提案手法が分類精度を改善する傾向を示した場合、VLM に単に分岐ラベルを選ばせるよりも、不確実性を中間概念に分解して診断させることが有効であると解釈できる。一方で、`stop` や `ask_user` を過剰に選択する傾向が確認された場合は、安全性重視と作業継続性のバランスを再検討する必要がある。

第 6 章 実験 2

6.1 本章の概要

本章では、工程文脈依存性を評価する実験2と、実機への接続可能性を確認する実験3について述べる。いずれも実験設計と評価方針を中心に整理する。

6.2 実験 2 の設定

実験 2 の目的は、同じ画像・同じ不確実性に対して、工程文脈が変化した場合に、VLM が処理分岐を適切に切り替えられるかを評価することである。比較対象は、現在工程なし、履歴なし、次工程候補なしのアプリケーション条件である。評価では、Branch Contrast Accuracy を中心に、工程文脈情報の有無が分岐切り替え性能へ与える影響を確認する。

6.3 評価の観点

実験完了後には、提案手法が同一画像に対して工程文脈だけを変えた場合でも、文脈に応じて分岐を切り替えられるかを確認する予定である。特に、履歴なし条件ではactとreobserveの区別が難しくなり、現在工程なし条件ではdeferの判断が不安定になる可能性があるため、これらの誤分類傾向を重点的に確認する。

表 6.1 実機デモにおける分岐別成功基準

分岐	成功基準
act	予定された primitive が安全ゲートを通過し、動作ログが保存される
reobserve	追加観測が実行され、再診断用の画像とログが保存される
ask_user	確認要求文が生成され、回答前は実行停止状態を維持する
stop	危険または不明条件で動作を抑制し、停止ログを保存する
defer	現在工程を継続し、不確実性を後工程の確認対象として記録する

6.4 実験 3：実機分岐デモ

実験 3 の目的は、提案手法による診断結果が、実機ロボットの安全な分岐判断に接続できるかを確認することである。具体的には、act すべき場面で予定 primitive へ進めるか、reobserve すべき場面で追加観測へ移れるか、ask_user すべき場面で人間確認へ回せるか、stop すべき場面で誤実行を避けられるか、defer すべき場面で過剰確認を避けられるかを評価する。

評価では、VLM 単独の直接判断と比較し、False Act Rate と unsafe non-stop rate が低下するかを確認する。

6.5 考察

実験 2 で高い Branch Contrast Accuracy が得られる傾向が確認できれば、長期タスク中の不確実性診断には、画像理解だけでなく、作業履歴と現在工程の利用が重要であると解釈できる。さらに、実験 3 で false act rate や unsafe non-stop rate の低下が確認できれば、提案手法が Physical AI における行動前確認の仕組みとして有効である可能性を示せる。一方で、ask_user や stop を過剰に選択する傾向が確認された場合は、実用上のテンポやユーザ負担とのトレードオフが課題となる。

第7章 考察

7.1 本章の概要

本章では、実験1から実験3を踏まえた総合的な考察を述べる。

7.2 結果の解釈

提案手法が分岐分類精度と Branch Contrast Accuracy を改善する傾向を示した場合、その意義は二つある。第一に、VLM に単に「次にどうするか」を答えさせるよりも、不確実性を証拠充足性、不確実性原因、工程関連性に分解して診断させることが有効であると解釈できる。第二に、同じ視覚状態でも工程文脈に応じて適切な分岐が変わるという、長期タスク固有の問題設定が妥当であることを裏づけられる。

7.3 手法の限界

本研究は、机上片付けを想定した限定的な長期タスクに基づくため、対象物、環境、ロボット身体が変わった場合の汎化性は十分に検証できない。また、VLM の自然言語理由は後付け説明である可能性があるため、理由文そのものではなく、構造化ラベルと分岐結果を中心に評価する必要がある。さらに、安全性を重視するほど ask_user や stop が増え、作業効率が低下するおそれがある。

7.4 今後の方向性

今後は、複数タスクへの拡張、VLA との接続、再観測視点の自動選択、ユーザ確認文の生成、実行後の回復行動との統合を検討する。また、world model や計画器と連携し、defer した不確実性を後工程で回収する仕組みへ拡張することも重要である。

第 8 章 結論

8.1 本研究のまとめ

本論文では、長期ロボットタスクにおける工程文脈依存的不確実性診断を対象とした。VLMを次行動生成器として用いるのではなく、現在画像、作業履歴、現在工程、次工程候補、工程条件リストを入力として、工程条件の不確実性を診断し、`act` / `reobserve` / `ask_user` / `stop` / `defer` の処理分岐へ接続する方法を提案した。

本研究の課題は、工程文脈依存的不確実性の整理、VLM による構造化診断方法の設計、同一視覚状態・異なる工程文脈の対照評価、および実機を含む安全性検証である。本論文の貢献は、第一に、長期タスク中の不確実性を処理分岐の観点から整理した点、第二に、VLM 出力を証拠充足性、不確実性原因、工程関連性、処理分岐として構造化した点、第三に、文脈依存的な分岐切り替え能力を評価対象として明示した点にある。

8.2 今後の課題

今後は、より多様な家庭内タスクや異なるロボットプラットフォームへの適用、再観測戦略の自動化、`ask_user` の対話設計、実行後の回復行動との統合が課題である。さらに、より大規模な計画器や world model と接続し、長期タスク全体の頑健性向上へ拡張する必要がある。

第 A 章 付録

A.1 補足資料

本研究では、工程条件ごとに evidence sufficiency、uncertainty source、task relevance、resolution mode、execution guard を付与した構造化アノテーションを想定している。付録には、今後、評価プロンプト例、アノテーション仕様、実機ログフォーマット、追加の対照ペア例を掲載する予定である。

参考文献

- [1] Benjamin Zitkovich et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Proceedings of the 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, pages 2165–2183, 2023.
- [2] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [3] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianliang Ding, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [4] Allen Z. Ren, Aastha Dixit, Anna Bodrova, Shubham Singh, Stephen Tu, Noah Brown, Peng Xu, et al. Robots that ask for help: Uncertainty alignment for large language model planners. In *Proceedings of the 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, 2023.
- [5] Vivek Sripada, Simon Carter, Frank Guerin, and Amir Ghalamzan. Ap-vlm: Active perception enabled by vision-language models. *arXiv preprint arXiv:2409.17641*, 2024.
- [6] Jiafei Duan, Walter Pumacay, Nishant Kumar, Y. R. Wang, Sirui Tian, Wei Yuan, Ranjay Krishna, et al. Aha: A vision-language-model for detecting and reasoning over failures in robotic manipulation. *arXiv preprint arXiv:2410.00371*, 2024.
- [7] Ruohan Zheng, Yixuan Liang, Siyuan Huang, Jun Gao, Hal Daumé III, Andrey Kolobov, Fei Huang, and Jie Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.
- [8] Haonan Shi, Bohan Xie, Yifan Liu, Liting Sun, Fangchen Liu, Tianhe Wang, E Zhou, et al. Memoryvla: Perceptual-cognitive memory in vision-language-action

- models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [9] Rui Li, Wenhao Guo, Zhen Wu, Cheng Wang, Haoran Deng, Zhe Weng, Yap-Peng Tan, and Zheng Wang. Map-vla: Memory-augmented prompting for vision-language-action model in robotic manipulation. *arXiv preprint arXiv:2511.09516*, 2025.
 - [10] Fangchen Liu, Kuan Fang, Pieter Abbeel, and Sergey Levine. Moka: Open-world robotic manipulation through mark-based visual prompting. In *Robotics: Science and Systems XX*, 2024.
 - [11] Oleg Kobzarev, Aleksei Lykov, and Dzmitry Tsetserukou. Gestllm: Advanced hand gesture interpretation via large language models for human-robot interaction. *arXiv preprint arXiv:2501.07295*, 2025.
 - [12] Aleksei Lykov, Oleg Kobzarev, and Dzmitry Tsetserukou. Gestos: Advanced hand gesture interpretation via large language models to control any type of robot. *arXiv preprint arXiv:2509.14412*, 2025.
 - [13] Dong Xia, Yue Shi, Yixuan Mu, Heng Ji, Cheng Ma, Yifan Zhou, Hao Chen, et al. Roboprocessbench: Benchmarking process-aware understanding in vision-language robotic manipulation. *arXiv preprint arXiv:2606.13040*, 2026.
 - [14] Alexander Curtis, George Matheos, Nikhil Gothoskar, Vikash Mansinghka, Joshua B. Tenenbaum, Tomás Lozano-Pérez, and Leslie Pack Kaelbling. Partially observable task and motion planning with uncertainty and risk awareness. In *Robotics: Science and Systems XX*, 2024.
 - [15] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Mike Rabbat, Yann LeCun, and Nicolas Ballas. V-jepa 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.
 - [16] Ruohan Zheng, Jialu Wang, Scott Reed, Johan Bjorck, Yixin Fang, Fan Hu, Jaehoon Jang, et al. Flare: Robot learning with implicit world modeling. *arXiv preprint arXiv:2505.15659*, 2025.